### main 02

October 5, 2024

#### 0.1 ideia - conceitos associados a empresas portuguesas

- decidir X empresas portuguesas
- analisar noticias sobre as mesmas e encontrar palavras/pessoas/temas associadas (fazer grafo) [ver se é positivo / negativo o termo/pessoa]
- tendo por base a tendência dessas palavras (+- faladas), analisar performance da empresa

Trabalho tem de ter 3 partes: 1. project structure + data acquisition 2. exploratory data analysis and visualization 3. results & discussion

Fonte de Dados: arquivo.pt (https://github.com/arquivo/pwa-technologies/wiki/Arquivo.pt-API) onde fui buscar site de notícias: https://www.kadaza.pt

pode ser preciso filtrar sites, pq não queremos primeiras páginas de notícias

```
[1]: import pandas as pd import requests
```

# 1 which companies to study

some PSI-20 companies

[2]: aliases

```
companies

Banco Comercial Português [Banco Comercial Português, BCP]

Galp Energia [Galp Energia, GALP]

EDP [EDP, Energias de Portugal, Electricidade de P...

Sonae [Sonae, SON]

Mota-Engil [Mota-Engil, EGL]
```

#### 2 where to grab the news from

```
[3]: def news(txtFile = 'noticias.txt'):
    """
    grab the news websites from a text file
    """
    with open(txtFile, 'r') as file:
        links = file.read().splitlines()
    return ",".join(links)
news()
```

[3]: 'www.publico.pt,publico.pt,www.dn.pt,www.rtp.pt,rpt.pt,www.cmjornal.pt,www.iol.p t,www.tvi24.iol.pt,tvi24.iol.pt,noticias.sapo.pt,observador.pt,expresso.pt,www.e xpresso.pt,sol.sapo.pt,www.jornaldenegocios.pt,www.jn.pt,jn.pt,ionline.pt,sicnot icias.pt,www.sicnoticias.pt,www.lux.iol.pt,www.ionline.pt,news.google.pt,www.din heirovivo.pt,www.aeiou.pt,aeiou.pt,www.tsf.pt,tsf.pt,www.sabado.pt,dnoticias.pt, www.dnoticias.pt,economico.sapo.pt,cnnportugal.iol.pt'

# 3 api requests in 3 years intervals

1 year to **3 years** is long enough to smooth out short-term fluctuations and identify underlying trends. Charts with weekly or monthly intervals over these periods show developments over full

economic/market cycles.

```
[4]: def api_request(search, websites, date):
         search: expression/word (what to look for)
         websites: comma separated websites (where to look for)
         date: list such as [20030101, 20031231] (when to look for)
         returns the responde_items from arquivo.pt api
         search = f"q=%22{search.replace(' ', '%20')}%22"
         websites = f"&siteSearch={websites}"
         date = f"&from={date[0]}&to={date[1]}"
         url = (
             f"https://arquivo.pt/textsearch?{search}{websites}{date}"
             "&fields=title,linkToArchive,tstamp,linkToExtractedText,snippet"
             "&maxItems=500&dedupValue=25&dedupField=url&prettyPrint=false&type=html"
         req = requests.get(url)
         json = req.json()
         data = json["response items"]
         if len(data) == 500:
             print(f"You might have lost some data: {search, date}")
         return data
```

```
[5]: df = pd.read_parquet("data01.parquet",)
    websites = news()

for cluster in range(2000, 2021, 3):
    api_cluster = [] #reset api_cluster for each cluster (group of 3 year)
    print(f"Processing cluster: {cluster}")
    print("Processing company:", end=" ")
    for company_aliases in df["aliases"]:
        api_company = [] #reset api_company for each company
        print(f"{company_aliases[0]}", end = "; ")

    for alias in company_aliases:
        for year in range(cluster, cluster + 3):

        api_aliasS1 = api_request(alias, websites, [int(f"{year}0101"), uesint(f"{year}0630")])
        api_aliasS2 = api_request(alias, websites, [int(f"{year}0701"), uesint(f"{year}1231")])
```

```
api_company += api_aliasS1 + api_aliasS2
             api_cluster.append(api_company)
         df[f"api.{cluster}"] = api_cluster
         print(f"{cluster} OK.")
     df.to_parquet("data02.parquet")
     print("Finished.")
    Processing cluster: 2000
    Processing company: Banco Comercial Português; Galp Energia; EDP; Sonae; Mota-
    Engil; 2000 OK.
    Processing cluster: 2003
    Processing company: Banco Comercial Português; Galp Energia; EDP; Sonae; Mota-
    Engil; 2003 OK.
    Processing cluster: 2006
    Processing company: Banco Comercial Português; Galp Energia; EDP; Sonae; Mota-
    Engil; 2006 OK.
    Processing cluster: 2009
    Processing company: Banco Comercial Português; Galp Energia; EDP; Sonae; Mota-
    Engil; 2009 OK.
    Processing cluster: 2012
    Processing company: Banco Comercial Português; Galp Energia; EDP; Sonae; Mota-
    Engil; 2012 OK.
    Processing cluster: 2015
    Processing company: Banco Comercial Português; Galp Energia; EDP; Sonae; Mota-
    Engil; 2015 OK.
    Processing cluster: 2018
    Processing company: Banco Comercial Português; Galp Energia; EDP; Sonae; Mota-
    Engil; 2018 OK.
    Finished.
[6]: df02 = pd.read_parquet("data02.parquet")
     df02
[6]:
                                                                           aliases \
     companies
    Banco Comercial Português
                                                  [Banco Comercial Português, BCP]
     Galp Energia
                                                              [Galp Energia, GALP]
     EDP
                                [EDP, Energias de Portugal, Electricidade de P...
                                                                      [Sonae, SON]
     Sonae
    Mota-Engil
                                                                 [Mota-Engil, EGL]
                                                                          api.2000 \
     companies
    Banco Comercial Português [{'linkToArchive': 'https://arquivo.pt/wayback...
```

```
Galp Energia
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
EDP
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
Sonae
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
Mota-Engil
                                                                       api.2003 \
companies
Banco Comercial Português
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
Galp Energia
EDP
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
Sonae
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
Mota-Engil
                                                                       api.2006 \
companies
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
Banco Comercial Português
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
Galp Energia
EDP
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
Sonae
Mota-Engil
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
                                                                       api.2009 \
companies
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
Banco Comercial Português
Galp Energia
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
EDP
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
Sonae
Mota-Engil
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
                                                                       api.2012 \
companies
Banco Comercial Português
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
Galp Energia
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
EDP
Sonae
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
Mota-Engil
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
                                                                       api.2015 \
companies
Banco Comercial Português
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
Galp Energia
EDP
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
Sonae
                            [{'linkToArchive': 'https://arquivo.pt/wayback...
Mota-Engil
                                                                       api.2018
```

companies

```
[{'linkToArchive': 'https://arquivo.pt/wayback...
     Banco Comercial Português
                                 [{'linkToArchive': 'https://arquivo.pt/wayback...
     Galp Energia
     EDP
                                 [{'linkToArchive': 'https://arquivo.pt/wayback...
     Sonae
                                 [{'linkToArchive': 'https://arquivo.pt/wayback...
     Mota-Engil
                                 [{'linkToArchive': 'https://arquivo.pt/wayback...
[7]: df02.map(lambda x: len(x))
[7]:
                                 aliases api.2000 api.2003 api.2006 api.2009 \
     companies
     Banco Comercial Português
                                       2
                                                153
                                                          241
                                                                     183
                                                                                561
     Galp Energia
                                       2
                                                128
                                                          389
                                                                     272
                                                                                582
     EDP
                                       3
                                                133
                                                          339
                                                                     173
                                                                               653
                                       2
                                                192
                                                          435
                                                                     279
                                                                               502
     Sonae
    Mota-Engil
                                       2
                                                  4
                                                           83
                                                                      60
                                                                                195
                                 api.2012
                                           api.2015
                                                      api.2018
     companies
     Banco Comercial Português
                                     1074
                                                1430
                                                            954
     Galp Energia
                                     1156
                                                1391
                                                           968
     EDP
                                     1232
                                                1970
                                                          1096
     Sonae
                                     1215
                                                1705
                                                          1196
     Mota-Engil
                                      538
                                                 828
                                                            560
[]:
```